

最优化方法

最优化方法概论

张伯雷

南京邮电大学 计算机学院

bolei.zhang@njupt.edu.cn

<http://bolei-zhang.github.io/course/opt.html>

目录

- 优化问题介绍
- 优化问题分类
- 典型优化问题
- 求解优化问题

优化问题案例1


还有一个星期就要到期末考试，小明一共要考 4 门课，但只能复习 70 个小时。令 $x = (x_1, x_2, x_3, x_4)$ 表示分别花在 4 门课上的复习时间。

- $f_i(x_i)$, $i = 1, 2, 3, 4$ 为小明投入 x_i 小时后第 i 门课的成绩


优化问题案例1

还有一个星期就要到期末考试，小明一共要考 4 门课，但只能复习 70 个小时。令 $x = (x_1, x_2, x_3, x_4)$ 表示分别花在 4 门课上的复习时间。


- $f_i(x_i)$, $i = 1, 2, 3, 4$ 为小明投入 x_i 小时后第 i 门课的成绩



优化问题案例1




优化问题案例1



问题建模

- 最大化最终的总分数: $\max_x \sum_{i=1}^4 f_i(x_i)$
- 每门课都需要及格, 同时总时间不能超过 70 小时: $\sum_{i=1}^4 x_i \leq 70, x_i \geq 0, f_i(x_i) \geq 60$

优化问题案例1



问题建模

- 最大化最终的总分数: $\max_x \sum_{i=1}^4 f_i(x_i)$
- 每门课都需要及格, 同时总时间不能超过 70 小时: $\sum_{i=1}^4 x_i \leq 70, x_i \geq 0, f_i(x_i) \geq 60$

如何规划复习时间?


优化问题案例2

小李是一个程序员，需要实现一个数据中心服务，当有用户请求服务时，需要尽快地服务用户请求，来降低整体延迟


优化问题案例2

小李是一个程序员，需要实现一个数据中心服务，当有用户请求服务时，需要尽快地服务用户请求，来降低整体延迟


- $d_i(x_i)$, $i = 1, 2, \dots, n$
- x_i 为向用户 i 分配的资源（如 CPU 配额）， $d_i(x_i)$ 为对应延迟，并假设它随 x_i 增大而下降



优化问题案例2




优化问题案例2



问题建模:

- 最小化整体延迟: $\min_x \sum_{i=1}^n d_i(x_i)$
- 不超过服务器总资源, 并满足各用户的资源上下限: $\sum_{i=1}^n x_i \leq C, l_i \leq x_i \leq u_i$

优化问题案例2



问题建模:

- 最小化整体延迟: $\min_x \sum_{i=1}^n d_i(x_i)$
- 不超过服务器总资源, 并满足各用户的资源上下限: $\sum_{i=1}^n x_i \leq C, l_i \leq x_i \leq u_i$

如何合理分配资源?

优化问题案例3

有一百万张图片，共分成 1000 个类别。神经网络输入图片 x_i ，输出类别概率 $q_\theta(y \mid x_i)$ 。训练网络就是调整参数 θ ，使真实类别 y_i 的预测概率尽可能大。

优化问题案例3

有一百万张图片，共分成 1000 个类别。神经网络输入图片 x_i ，输出类别概率 $q_\theta(y \mid x_i)$ 。训练网络就是调整参数 θ ，使真实类别 y_i 的预测概率尽可能大。

- 问题建模:

$$\min_{\theta} -\frac{1}{N} \sum_{i=1}^N \log q_\theta(y_i \mid x_i)$$

优化问题案例3

有一百万张图片，共分成 1000 个类别。神经网络输入图片 x_i ，输出类别概率 $q_\theta(y \mid x_i)$ 。训练网络就是调整参数 θ ，使真实类别 y_i 的预测概率尽可能大。

- 问题建模:

$$\min_{\theta} -\frac{1}{N} \sum_{i=1}^N \log q_\theta(y_i \mid x_i)$$

如何在海量的数据上优化神经网络参数？

优化问题案例4

有一个在大量文本语料上训练的大语言模型，为了让大语言模型的输出“靠近”人类偏好/价值观，需要通过调整大语言模型，使得在各种输入下模型的输出最大化人类回报、最小化偏差和风险、并满足安全等约束。

优化问题案例4

有一个在大量文本语料上训练的大语言模型，为了让大语言模型的输出“靠近”人类偏好/价值观，需要通过调整大语言模型，使得在各种输入下模型的输出最大化人类回报、最小化偏差和风险、并满足安全等约束。

- 问题建模:

$$\max_{\theta} \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi_{\theta}(\cdot|x)} [r_{\phi}(x, y)] - \beta D_{\text{KL}}(\pi_{\theta} \parallel \pi_{\text{ref}})$$

- $r_{\phi}(x, y)$ 是由人类反馈学习得到的奖励模型，KL 正则项限制策略偏离参考模型
- 安全、公平等要求需要另行写成约束，例如 $c_j(\theta) \leq \varepsilon_j$

优化问题案例4

有一个在大量文本语料上训练的大语言模型，为了让大语言模型的输出“靠近”人类偏好/价值观，需要通过调整大语言模型，使得在各种输入下模型的输出最大化人类回报、最小化偏差和风险、并满足安全等约束。

- 问题建模:

$$\max_{\theta} \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi_{\theta}(\cdot|x)} [r_{\phi}(x, y)] - \beta D_{\text{KL}}(\pi_{\theta} \parallel \pi_{\text{ref}})$$

- $r_{\phi}(x, y)$ 是由人类反馈学习得到的奖励模型，KL 正则项限制策略偏离参考模型
- 安全、公平等要求需要另行写成约束，例如 $c_j(\theta) \leq \varepsilon_j$

人类偏好不可直接观测（只能通过比较、反馈或行为间接得到）、偏好可能模糊/多样且会变动、模型有能力利用奖励的漏洞（reward hacking），并且问题是非凸、样本稀缺且存在分布迁移。

应用领域

- 网络优化
- 大规模电路设计
- 机器学习
- 推荐系统
- 物流运输、路线规划
- 工业设计、工业控制
- 金融经济
- ...

优化 (Optimization / Mathematical Programming)

优化问题 (Optimization Problem)

$$\begin{aligned} \min_x \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0, \quad i = 1, \dots, m, \\ & h_j(x) = 0, \quad j = 1, \dots, p, \\ & x \in X. \end{aligned}$$

优化 (Optimization / Mathematical Programming)

优化问题 (Optimization Problem)


$$\begin{aligned} \min_x \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0, \quad i = 1, \dots, m, \\ & h_j(x) = 0, \quad j = 1, \dots, p, \\ & x \in X. \end{aligned}$$

- $x = (x_1, x_2, \dots, x_n)$: 优化变量 (variable)
- $f_0 : \mathbb{R}^n \rightarrow \mathbb{R}$: 目标函数 (objective function)
- $f_i : \mathbb{R}^n \rightarrow \mathbb{R}$: 不等式约束函数; $h_j : \mathbb{R}^n \rightarrow \mathbb{R}$: 等式约束函数
- X : 变量的定义域, 满足全部约束的点构成可行集
- 最优解 x^* : 可行集中使目标函数 f_0 取得最小值的点
- 最优值 $p^* = f_0(x^*)$

例1


$$f_0(x) = x^2 - 2x + 3 = (x - 1)^2 + 2$$

- 变量: $x \in \mathbb{R}$
- 目标函数: $f_0(x) = x^2 - 2x + 3$
- 约束: 无
- 最优解: $x^* = 1$
- 最优值: $p^* = 2$



例2

- 变量: $x \in \mathbb{R}$
- 目标函数: $f_0(x)$
- 约束: $a \leq x \leq b$
- 全局最优解: $x^* \in \arg \min_{a \leq x \leq b} f_0(x)$
- 最优值: $p^* = \min_{a \leq x \leq b} f_0(x)$
- 图中存在多个局部极小点, 求解时需要区分局部最优与全局最优



目录

- 优化问题介绍
- 优化问题分类
- 典型优化问题
- 求解优化问题


最优化问题分类：线性/非线性分类

线性规划

- 如果目标函数与约束函数都是仿射函数，则为线性规划（Linear Programming）

$$f_i(x) = a_i^\top x + b_i, \quad i = 0, 1, \dots, m$$

- 单纯形法(simplex method)




最优化问题分类：线性/非线性分类

线性规划

- 如果目标函数与约束函数都是仿射函数，则为线性规划 (Linear Programming)

$$f_i(x) = a_i^\top x + b_i, \quad i = 0, 1, \dots, m$$

- 单纯形法(simplex method)



非线性规划

- 如果目标函数与约束函数不一定是线性的，则为非线性规划 (Non-Linear programming)

最优化问题分类：凸/非凸规划

凸规划

- 定义域是凸集，目标函数和不等式约束函数均为凸函数；等式约束必须是仿射函数

$$f_i(\lambda x + (1 - \lambda)y) \leq \lambda f_i(x) + (1 - \lambda)f_i(y), \quad \lambda \in [0, 1]$$

最优化问题分类：凸/非凸规划

凸规划

- 定义域是凸集，目标函数和不等式约束函数均为凸函数；等式约束必须是仿射函数

$$f_i(\lambda x + (1 - \lambda)y) \leq \lambda f_i(x) + (1 - \lambda)f_i(y), \quad \lambda \in [0, 1]$$

非凸规划

- 可行解集不是凸集或目标函数不是凸函数

最优化问题分类：光滑/非光滑规划

光滑规划

- 如果目标函数 $f_0(x)$ 连续可微，则称为光滑优化问题
- 在分析梯度法时，通常还会进一步假设梯度满足 Lipschitz 连续条件

非光滑规划

- 目标函数在部分点不可微，例如 $\|x\|_1$

最优化问题分类：连续/离散规划

连续优化

- 决策变量在实数域中取值，例如 $x \in \mathbb{R}^n$

离散优化

- 部分或全部决策变量只能取整数、布尔值或有限集合中的值

最优化问题分类：单目标/多目标规划

多目标规划

- 同时优化由多个分量构成的向量目标

$$\min_x (f_1(x), f_2(x), \dots, f_k(x))$$

- 通常用 Pareto 最优描述目标之间的权衡
- 加权和可以得到部分 Pareto 解，但在非凸情形下不一定覆盖整个 Pareto 前沿

多主体优化：博弈

面对警察的单独审讯，Alice和Bob分别可以选择隐瞒或者坦白，并在选择之后会面临相应的刑期，什么是最优的选择？

Alice\Bob	隐瞒	坦白
隐瞒	$(-1, -1)$	$(-5, 0)$
坦白	$(0, -5)$	$(-4, -4)$

多主体优化：博弈


面对警察的单独审讯，Alice和Bob分别可以选择隐瞒或者坦白，并在选择之后会面临相应的刑期，什么是最优的选择？

Alice\Bob	隐瞒	坦白
隐瞒	$(-1, -1)$	$(-5, 0)$
坦白	$(0, -5)$	$(-4, -4)$

双方的占优策略都是“坦白”，因此唯一 Nash 均衡为 $(-4, -4)$ ；但 $(-1, -1)$ 对双方都更好，说明个体最优与整体最优可能冲突。

最优化问题分类：确定/随机优化

- 确定性优化：目标函数和约束中的参数已知且固定
- 随机优化：目标函数或约束包含随机变量，通常优化期望、概率约束或风险度量




目录

- 优化问题介绍
- 优化问题分类
- 典型优化问题
- 求解优化问题


典型优化问题-最小二乘

数据拟合问题



典型优化问题-最小二乘

数据拟合问题



- 目标函数

$$\min_{\theta} \sum_{i=1}^N (y_i - f_{\theta}(x_i))^2$$

典型优化问题-稀疏优化

考虑线性方程组求解问题 $Ax = b$

- 其中 $x \in \mathbb{R}^n$, $b \in \mathbb{R}^m$, $A \in \mathbb{R}^{m \times n}$
- 向量 b 的维度远小于向量 x 的维度, 即 $m \ll n$
- 在信号传输过程中, 希望通过接收到长度为 m 的数字信号 b 精确地重构原始信号 x
- 方程组是欠定的, 因此存在无穷多个解, 重构出原始信号看似很难

典型优化问题-稀疏优化

考虑线性方程组求解问题 $Ax = b$

- 其中 $x \in \mathbb{R}^n$, $b \in \mathbb{R}^m$, $A \in \mathbb{R}^{m \times n}$
- 向量 b 的维度远小于向量 x 的维度, 即 $m \ll n$
- 在信号传输过程中, 希望通过接收到长度为 m 的数字信号 b 精确地重构原始信号 x
- 方程组是欠定的, 因此存在无穷多个解, 重构出原始信号看似很难

稀疏先验: 真实解 u 只有约 10% 的元素非零, 可建立问题

$$\min_x \|x\|_0 \quad \text{s.t.} \quad Ax = b$$

- $\|x\|_0$ 表示非零元素个数, 严格来说不是范数; 该问题通常是 NP 难的

典型优化问题-稀疏优化


考虑线性方程组求解问题 $Ax = b$

- 其中 $x \in \mathbb{R}^n$, $b \in \mathbb{R}^m$, $A \in \mathbb{R}^{m \times n}$
- 向量 b 的维度远小于向量 x 的维度, 即 $m \ll n$
- 在信号传输过程中, 希望通过接收到长度为 m 的数字信号 b 精确地重构原始信号 x
- 方程组是欠定的, 因此存在无穷多个解, 重构出原始信号看似很难


稀疏先验: 真实解 u 只有约 10% 的元素非零, 可建立问题

$$\min_x \|x\|_0 \quad \text{s.t.} \quad Ax = b$$


- $\|x\|_0$ 表示非零元素个数, 严格来说不是范数; 该问题通常是 NP 难的



l_1



l_0 (a) 精确解 u



l_2

典型优化问题-低秩矩阵恢复

某视频网站拥有约 48 万用户对 1.7 万余部电影的上亿条评分，希望预测缺失评分，从而改进推荐结果。用矩阵 M 表示已观测评分：每行对应一个用户，每列对应一部电影。

	电影 1	电影 2	电影 3	电影 4	...	电影n
用户 1	4	?	?	3	...	?
用户 2	?	2	4	?	...	?
用户 3	3	?	?	?	...	?
用户 4	2	?	5	?	...	?
⋮	⋮	⋮	⋮	⋮		⋮
用户m	?	3	?	4	...	?

典型优化问题-低秩矩阵恢复


某视频网站拥有约 48 万用户对 1.7 万余部电影的上亿条评分，希望预测缺失评分，从而改进推荐结果。用矩阵 M 表示已观测评分：每行对应一个用户，每列对应一部电影。

	电影 1	电影 2	电影 3	电影 4	...	电影 n
用户 1	4	?	?	3	...	?
用户 2	?	2	4	?	...	?
用户 3	3	?	?	?	...	?
用户 4	2	?	5	?	...	?
⋮	⋮	⋮	⋮	⋮		⋮
用户 m	?	3	?	4	...	?

$$\begin{aligned} \min \quad & \text{rank}(X), \\ \text{s.t.} \quad & X_{ij} = M_{ij}, (i, j) \in \Omega \end{aligned}$$

典型优化问题-深度学习


深度学习分类问题（以交叉熵损失为例）



$$y_i^{(l)} = t(z_i^{(l)}), \quad z_i^{(l)} = \sum_{k=1}^{m^{(l-1)}} x_{i,k}^{(l)} y_k^{(l-1)}.$$
$$t(z) = \frac{1}{1 + \exp(-z)},$$

典型优化问题-深度学习

深度学习分类问题（以交叉熵损失为例）



$$y_i^{(l)} = t(z_i^{(l)}), \quad z_i^{(l)} = \sum_{k=1}^{m^{(l-1)}} x_{i,k}^{(l)} y_k^{(l-1)}.$$
$$t(z) = \frac{1}{1 + \exp(-z)},$$

$$\min_{\theta} - \frac{1}{m} \sum_{i=1}^m \log q_{\theta}(y_i | a_i) + \lambda r(\theta)$$

目录

- 优化问题介绍
- 优化问题分类
- 典型优化问题
- 求解优化问题

优化问题

对有限资源进行有效分配和控制，并达到某种意义上的最优。

- 对需求进行定性和定量分析
- 建立恰当的数学模型来描述该问题
- 探索研究模型和算法的理论性质，考察算法的计算性能等
- 设计合适的计算方法来寻找问题的最优解

凸优化问题的判定

判断标准



- 定义域是凸集
- 目标函数和所有不等式约束函数是凸函数
- 所有等式约束函数是仿射函数

非凸问题有时可以通过变量替换或松弛转化为凸问题；对偶化并不自动使非凸问题等价地变成凸问题。

优化算法

闭式解 (closed form solution)

- 如果我们能用代数表达式给出其最优解，那么这个解称为闭式解，对应的问题往往比较简单
- 例如：二次函数在有界区间上





优化算法

闭式解 (closed form solution)

- 如果我们能用代数表达式给出其最优解，那么这个解称为闭式解，对应的问题往往比较简单
- 例如：二次函数在有界区间上

实际大多数问题是没有闭式解的，需要通过迭代算法求解

- 迭代算法从初始点 x^0 出发，按照给定规则产生序列 $\{x^k\}$ ；希望该序列收敛到最优解，并在误差、梯度或迭代次数满足停止条件时终止
- 例如：梯度类算法、线搜索法、罚函数法



常用优化技巧

泰勒展开

$$f(x) = \sum_{k=0}^n \frac{f^{(k)}(x_0)}{k!} (x - x_0)^k + R_n(x)$$

常用优化技巧

泰勒展开

$$f(x) = \sum_{k=0}^n \frac{f^{(k)}(x_0)}{k!} (x - x_0)^k + R_n(x)$$

对偶

- 拉格朗日对偶给出原问题最优值的下界；满足适当正则条件（如 Slater 条件）时，凸问题可具有强对偶。对偶问题有时更易求解，但并非总是如此

常用优化技巧

泰勒展开

$$f(x) = \sum_{k=0}^n \frac{f^{(k)}(x_0)}{k!} (x - x_0)^k + R_n(x)$$

对偶

- 拉格朗日对偶给出原问题最优值的下界；满足适当正则条件（如 Slater 条件）时，凸问题可具有强对偶。对偶问题有时更易求解，但并非总是如此

拆分

- 通过引入辅助变量等方法，将一个复杂的优化问题拆分成多个相对简单的子问题

课程目标

目标

- 识别/建模 哪些问题是凸优化问题
- 通过代码对相对简单的凸优化问题进行求解
- 判断最优解，给出算法性能极限等
- 针对实际的大规模、大数据等问题进行求解

课程目标

目标

- 识别/建模 哪些问题是凸优化问题
- 通过代码对相对简单的凸优化问题进行求解
- 判断最优解，给出算法性能极限等
- 针对实际的大规模、大数据等问题进行求解

主要内容

- 凸集、凸函数、凸优化问题
- 凸优化理论
- 优化建模
- 优化算法
- 大数据优化、深度学习等

优化问题的历史

将欲歛之，必固张之；将欲弱之，必固强之；将欲废之，必固兴之；将欲夺
之，必固与之
——《道德经》

优化问题的历史

将欲歛之，必固张之；将欲弱之，必固强之；将欲废之，必固兴之；将欲夺之，必固与之
——《道德经》

历史

- 17—18 世纪：Newton 与 Raphson 提出求解 $f(x) = 0$ 的迭代思想
- 18 世纪：Lagrange 提出拉格朗日乘子法
- 20 世纪上半叶：凸分析、线性规划与博弈论逐步形成
- 1944 年：von Neumann 与 Morgenstern 系统奠定博弈论基础
- 1950 年：Nash 提出非合作博弈均衡；1950 年代初 Bellman 发展动态规划

优化问题的历史

将欲歛之，必固张之；将欲弱之，必固强之；将欲废之，必固兴之；将欲夺之，必固与之
——《道德经》

历史

- 17—18 世纪：Newton 与 Raphson 提出求解 $f(x) = 0$ 的迭代思想
- 18 世纪：Lagrange 提出拉格朗日乘子法
- 20 世纪上半叶：凸分析、线性规划与博弈论逐步形成
- 1944 年：von Neumann 与 Morgenstern 系统奠定博弈论基础
- 1950 年：Nash 提出非合作博弈均衡；1950 年代初 Bellman 发展动态规划

算法

- 单纯形法 (Dantzig 1947)
- 内点法, 次梯度法
- 1979 年：Khachiyan 用椭球法证明线性规划可在多项式时间内求解
- 20 世纪 80—90 年代：内点法进一步发展并推广到凸二次规划和非线性凸优化

谢谢!

